АНАЛИЗ ДАННЫХ РАСПРЕДЕЛЁННЫХ ВОЛОКОННО-ОПТИЧЕСКИХ ДАТЧИКОВ

Аналитический отчёт по 4.csv и 5.csv
Структура данных · нормальное поведение · аномалии · корреляции

Ключевые результаты

Показатель	4.csv	5.csv
Дата измерений	26.05.2026	16.10.2025
Число измерений	708	2 711
Корректных координат X	1 691	1 689
Медиана Y	24,78	20,59
Максимальное Y	35,29	34,33
Подозрительных кластеров повышения	46	81

4.csv: устойчивый рост сигнала в районе X≈87–120. Кластер у X≈111,66 фиксировался с 15:03 до 23:59 UTC, пиковое отклонение от скорректированного фона +10,24 единицы Y.

5.csv: более краткие локальные события. В точке X=418 зафиксирован эпизод около 12:17–12:20 с отклонением до +13,61 единицы Y.

Качество: в 5.csv последние 675 координат каждой записи равны -300; это 1 829 925 некорректных ячеек, исключённых из расчётов.

Важно: 46 и 81 — количество статистически выделенных кластеров, а не подтверждённых повреждений кабеля. Единицы измерения X и Y не указаны в CSV; °C, метры и пороги опасности требуют подтверждения по спецификации оборудования.

Соответствие заданию хакатона

Отчёт раскрывает структуру двух наборов данных, описывает понятие нормы, выявляет и ранжирует аномалии, исследует пространственные корреляции и разграничивает статистические наблюдения и технические выводы.

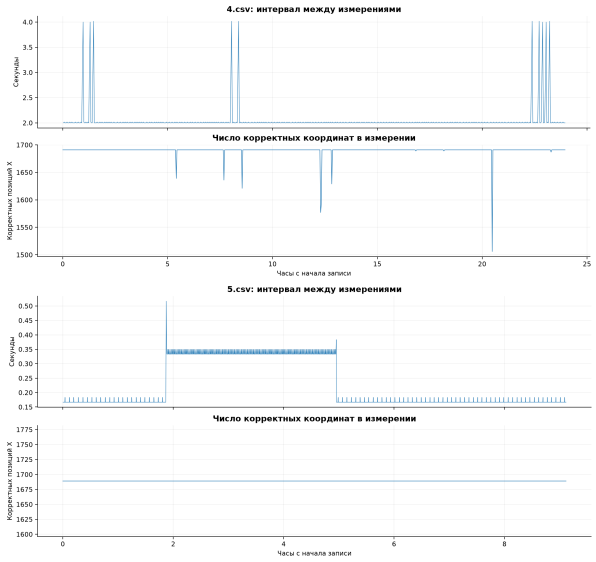
01 | Структура и качество исходных данных

Одна строка CSV — один временной профиль измерений. Поля: **dts_id** (идентификатор набора/датчика), **channel_id** (канал), **timestamp** (время), **points** (массив пар [X, Y]). X трактуется как координата/позиция, Y — наблюдаемый сигнал, предположительно температура.

Характеристика	4.csv	5.csv
Временной охват	00:01:53–23:59:07 UTC	12:00:06–21:07:00, часовой пояс не задан
Типичный шаг времени	120–121 с	10–11 с; местами 20–21 с
Сетка X	0–428,873; шаг ≈0,253771	0–2363; шаг 1
Точек в профиле	Обычно 1 691; 10 неполных	2 364; последние 675 равны -300
Корректных значений Y	1 196 583	4 578 879

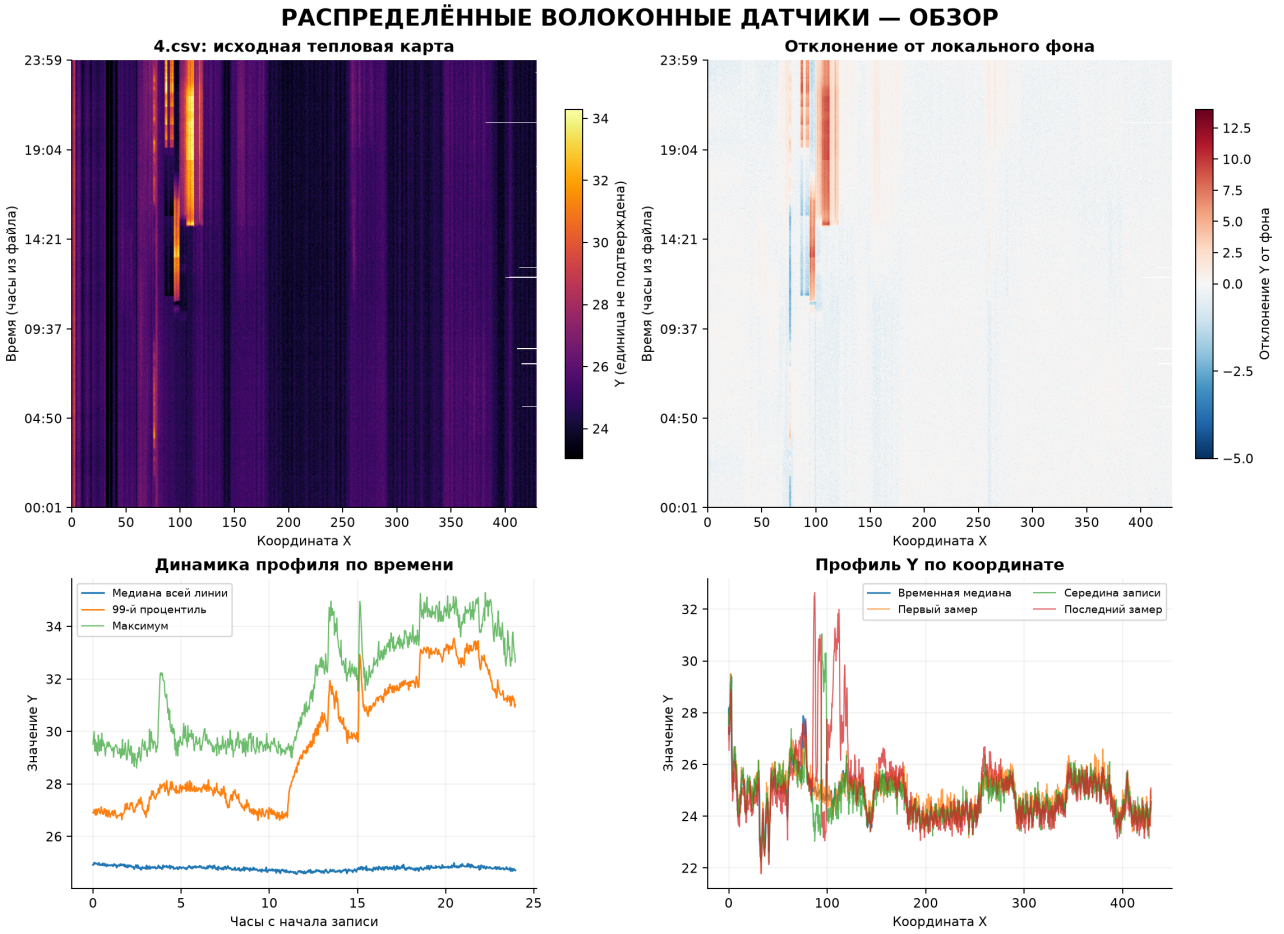
Найденные проблемы качества

- **4.csv:** 10 укороченных профилей (645 отсутствующих значений) и 10 удлинённых интервалов порядка 240–241 секунд.
- **5.csv:** значения -300 в координатах X=1689–2363 на каждой временной отметке; нельзя трактовать как реальную температуру.
- **5.csv:** изменение частоты измерений примерно с 13:52 до 16:57; методика сравнения динамики должна учитывать неравномерный шаг времени.
- Даты и шкалы X двух файлов различаются: одинаковый индекс точки не означает одинаковый физический участок.



02 | Пространственно-временной анализ: 4.csv

Тепловая карта слева отображает исходный Y, справа — остаточное отклонение после вычитания медианного уровня каждой позиции и общей сдвиговой компоненты в каждой записи. Наиболее выраженные события приходятся на участок X≈87–120.

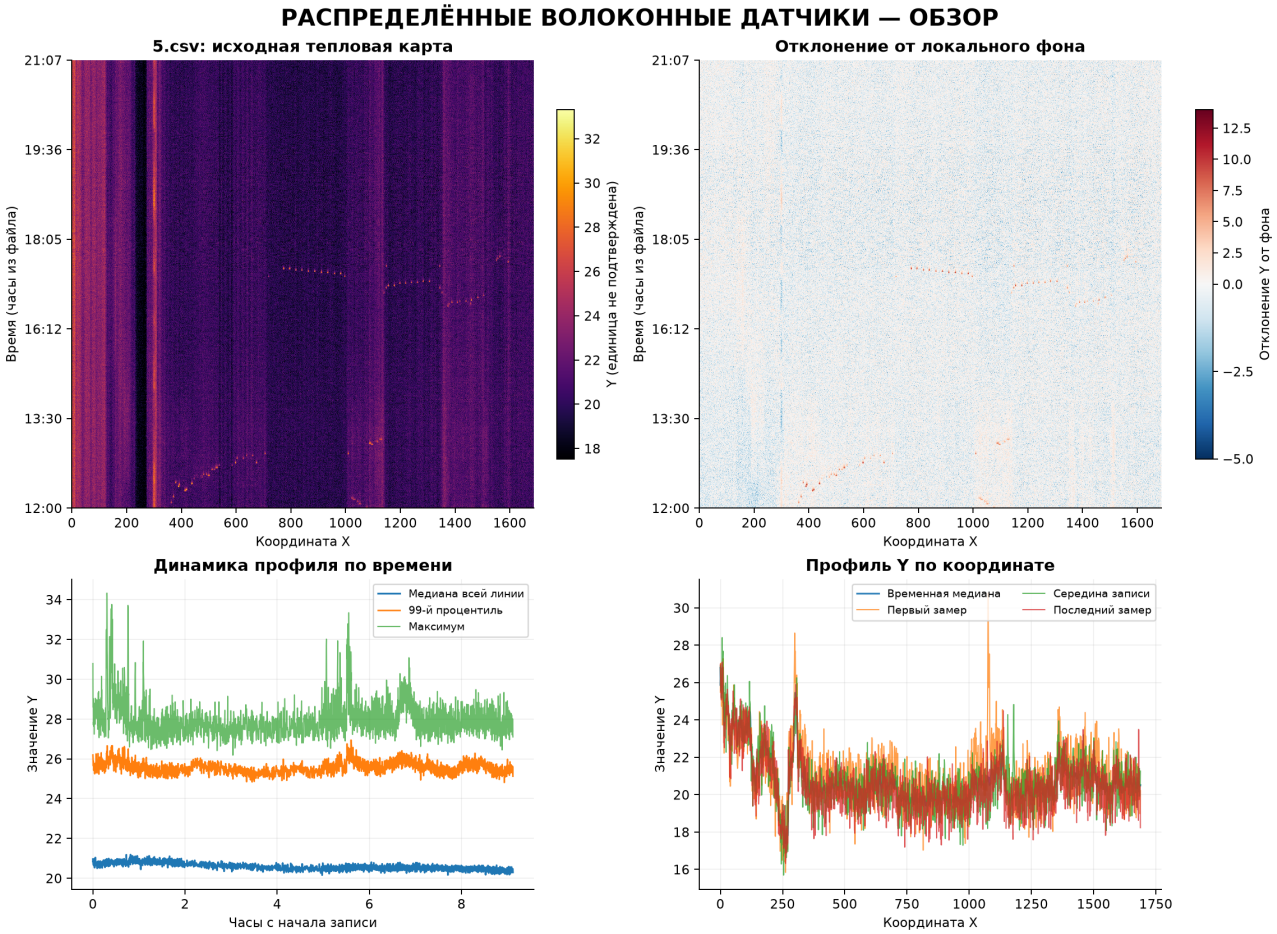


Для большей части линии общая медиана изменяется умеренно. При этом высокие квантили и максимум растут локально: это не равномерный нагрев всей линии.

Светлые пропуски на конце некоторых профилей вызваны отсутствием данных, а не падением температуры.

03 | Пространственно-временной анализ: 5.csv

В отличие от 4.csv, заметны преимущественно краткие локальные повышения в разных координатах: X≈392, 418, 439, 598 и 935. Участок X≥1689 исключён: там всегда записан код -300.



Типичный уровень Y ниже, чем в 4.csv, но без подтверждённых единиц измерения, геопривязки, калибровки и режима работы нельзя интерпретировать разность как изменение состояния одного и того же кабеля.

Интерактивная демонстрация позволяет показать для каждого события его **время, координату и амплитуду**.

04 | Что считается нормой и аномалией

Статистическая норма: при фиксированном X показание Y обычно находится в пределах типичных колебаний относительно собственной исторической медианы этой координаты. Общие изменения всей линии учитываются отдельно. Один абсолютный порог для всех X не используется.

Алгоритм: медиана Y по времени для каждого X → удаление общей медианной компоненты по пространству в каждом измерении → оценка шума через 1,4826 × MAD → выделение точек при |остаток| > max(3 единицы Y; 5 × локальный MAD). Затем объединение соседних ячеек по времени/координате и отбрасывание слишком маленьких изолированных кластеров.

Категория	Признаки	Интерпретация
Нормальное поведение	Колебания вокруг собственного фона	Наблюдение
Повышение Y	Положительное превышение локального порога	Проверить тепловое событие
Понижение Y	Отрицательное превышение локального порога	Проверить среду и измеритель
Проблема данных	-300, пропуски, смена частоты	Исключить или пометить

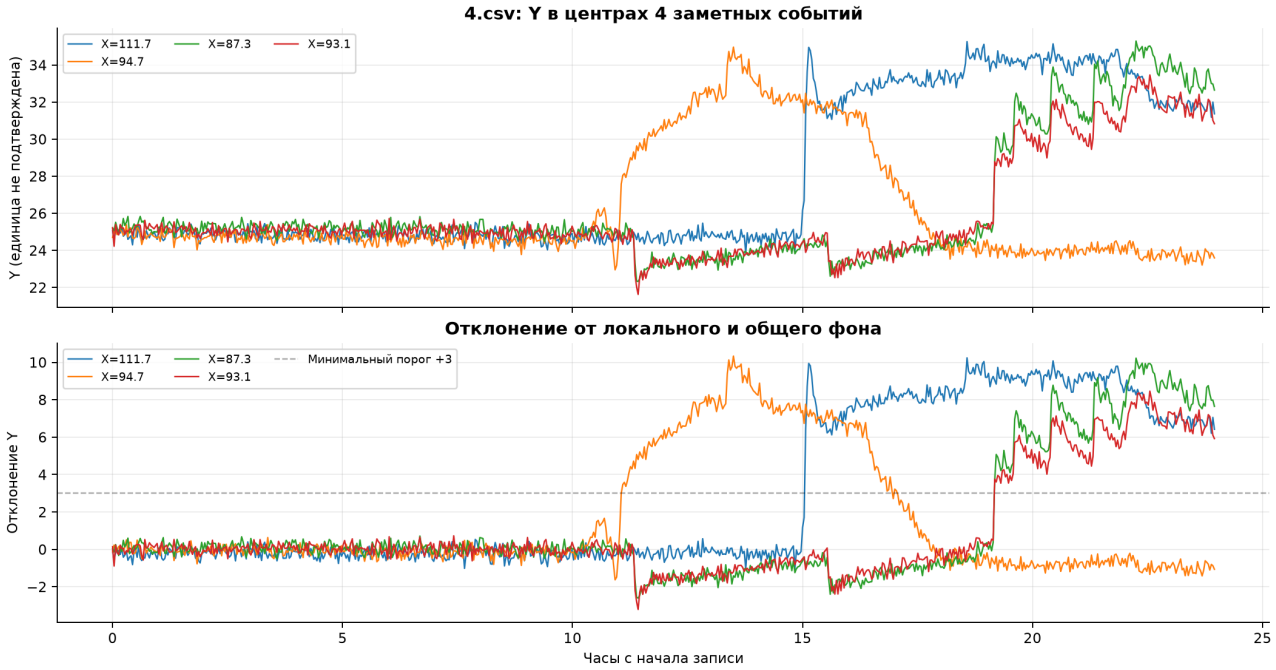
Ограничения

- 3 единицы Y и 5 × MAD — рабочие параметры исследовательского детектора, а не нормативы тепловой безопасности.
- Алгоритм не обучен на размеченных повреждениях: оценить точность, полноту и долю ложных тревог пока нельзя.
- Конец записи обрывает некоторые события: фактическая продолжительность может быть больше наблюдаемой.
- Кластер может отражать нагрев, изменение нагрузки, окружающую среду или артефакт измерения — требуется техническая проверка.

05 | Аномальные события в 4.csv

При выбранных параметрах обнаружено **46 кластеров повышения Y**, требующих проверки. Ниже — наиболее заметные события согласно внутреннему баллу (балл не является показателем опасности).

Диапазон X	Время, начало — конец	Пик ΔY	Замеров
101.255–113.182	15:03–23:59	+10.24	263
94.149–98.971	11:07–16:54	+10.33	174
85.521–88.312	19:34–23:59	+10.22	128
90.342–93.642	19:12–23:59	+8.46	139
116.735–119.019	15:28–23:59	+6.46	251



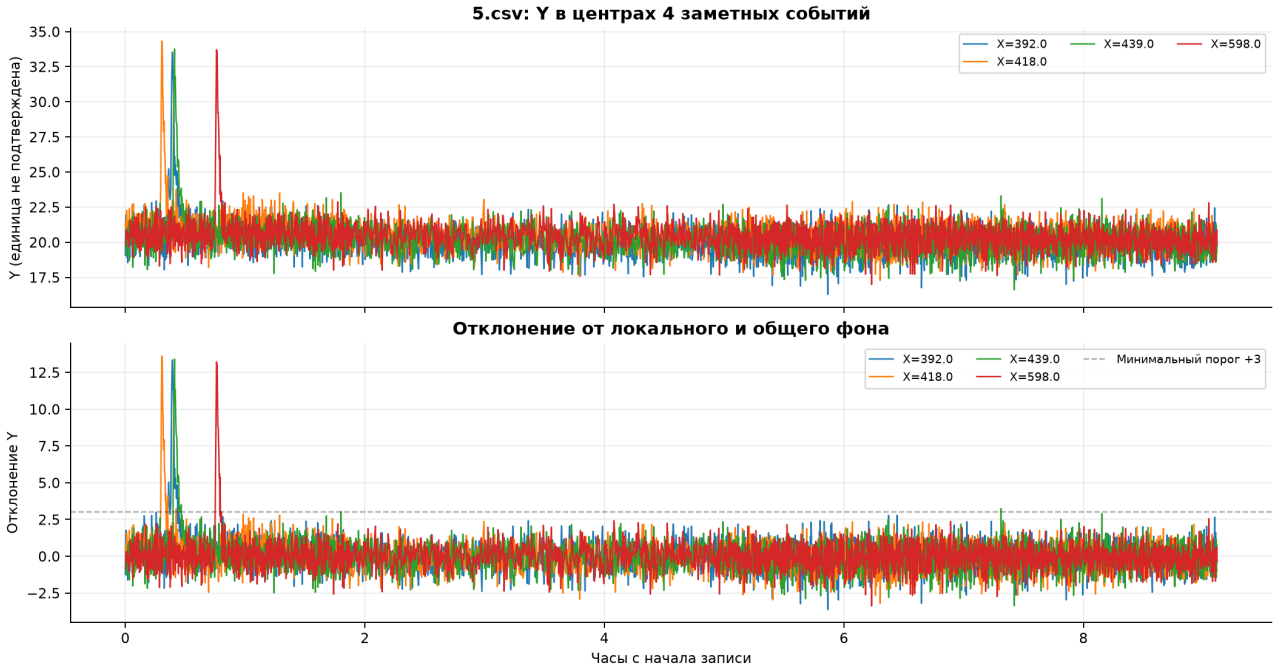
Пример: около X=111,66 аномалия наблюдается с 15:03:57 до 23:59:07 UTC, охватывает 263 измерения; максимальный Y≈35,26, остаточное отклонение +10,24.

Нужно сопоставить рост со временем повышения нагрузки, внешними источниками тепла и схемой прокладки кабеля. Близкие пространственные кластеры не обязательно являются одним дефектом.

06 | Аномальные события в 5.csv

При выбранных параметрах обнаружен **81 кластер повышения Y**. Большинство значимых событий короче, чем в 4.csv: часть длится лишь несколько минут.

Диапазон X	Время, начало — конец	Пик ΔY	Замеров
387.0–395.0	12:21–12:25	+13.34	28
411.0–421.0	12:17–12:20	+13.61	19
436.0–441.0	12:24–12:26	+13.41	17
596.0–600.0	12:45–12:47	+13.21	14
933.0–937.0	17:31–17:33	+13.21	13

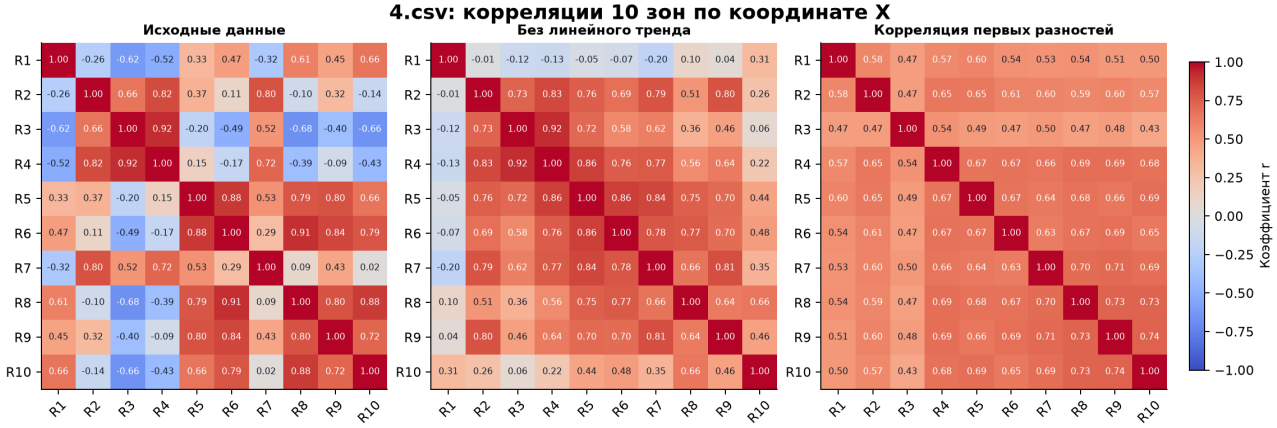


Пример: у X=418 максимум Y≈34,33, отклонение от скорректированного фона +13,61, период наблюдения примерно 12:17–12:20. Временная зона этой записи не задана.

Быстрый всплеск необходимо перепроверить по соседним позициям, временному профилю, исходному сигналу и журналу измерителя. Одного превышения недостаточно для диагноза «опасный перегрев».

07 | Корреляции между зонами: 4.csv

1 691 корректная позиция разделена на 10 последовательных зон R1–R10. Для каждой временной отметки вычислено среднее Y по зоне. Далее сравниваются исходный Пирсон, Пирсон после удаления линейного тренда и Пирсон по первым разностям.



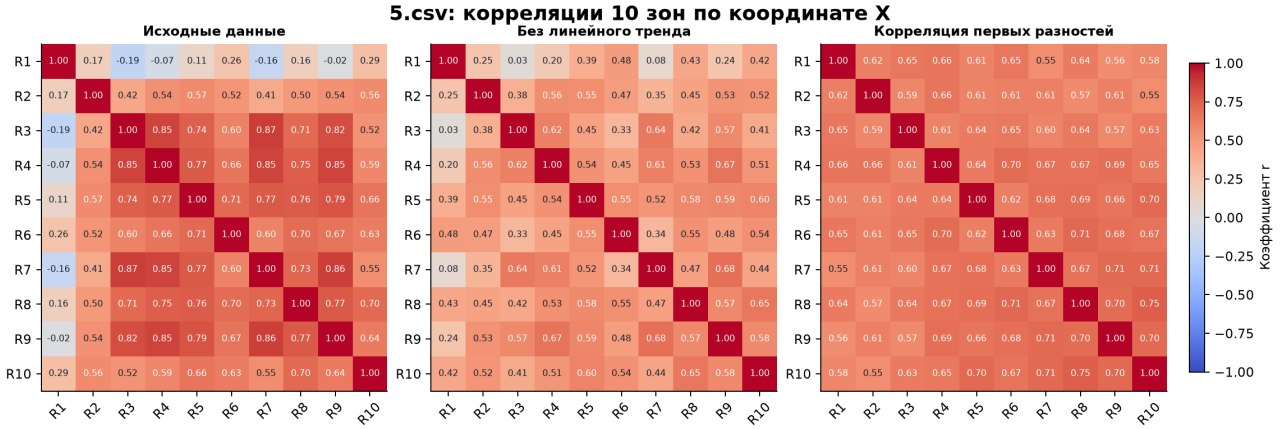
Пара зон	r исходный	r без тренда
R3 (≈86–129) и R4 (≈129–172)	+0,922	+0,917
R5 (≈172–214) и R6 (≈215–257)	+0,885	+0,862

Сильная связь R3–R4 сохраняется после удаления линейного тренда. Это соответствует согласованной динамике, но ещё не доказывает перенос тепла между зонами. Причинами могут быть общая нагрузка, среда или особенности измерительной системы.

Средние значения по крупным зонам сглаживают узкие горячие точки. Для инженерной интерпретации полезно дополнить анализ более узкими зонами и анализом задержек.

08 | Корреляции между зонами: 5.csv

Использована та же схема по 1 689 корректным позициям X=0–1688. Поскольку сетка X отличается от 4.csv, одинаковый номер зоны между файлами не означает физического совпадения.



Пара зон	r исходный	r без тренда
R3 (338–506) и R7 (1014–1182)	+0,873	+0,642
R7 (1014–1182) и R9 (1352–1520)	+0,862	+0,683

В паре R3–R7 коэффициент снижается с 0,873 до 0,642 после удаления линейного тренда. Следовательно, часть исходной связи обусловлена общим временным изменением.

Первые разности позволяют оценить кратковременные совместные колебания, но чувствительны к шуму и переменной частоте записи. Без учёта временной автокорреляции обычные p-значения будут ненадёжны.

09 | Выводы и план дальнейшей проверки

Четыре обязательных результата хакатона

- **Структура:** восстановлены матрицы «время × X», проверены частоты, пропуски, некорректные значения и диапазоны координат.
- **Аномалии:** создан перечень 127 подозрительных кластеров повышения Y с координатами, временем, длительностью, размахом и приоритетом просмотра.
- **Норма:** определена через медианный локальный фон и адаптивный разброс каждой позиции; аномалии отделены от неисправных данных.
- **Корреляции:** построены матрицы для 10 зон обоих файлов, в том числе после детрендирования и по первым разностям.

Что нужно уточнить у организаторов

- Y измеряется в градусах Цельсия? Это температура волокна, оболочки кабеля или оценка температуры объекта?
- X — метры, позиция датчика или условный индекс? Оба файла относятся к одной линии?
- Что официально означает значение -300 и какова точность/калибровка измерителя?
- Есть ли журналы нагрузки, погодных условий, технического обслуживания и экспертная разметка реальных событий?

Предложение для демонстрации

Показать тепловую карту, выбор точки X, временную динамику, список подозрительных событий и матрицу корреляций. На примере 4.csv объяснить длительный рост; на примере 5.csv — краткий локальный всплеск. Отдельно подчеркнуть границы достоверности.

Артефакты проекта

analysis.py, visuals.py, dashboard.py, make_report.py, make_demo_html.py, dashboard_demo.html, anomaly_events.csv, anomaly_events_ru.csv, summary.json, figures/, correlation_*.csv и README.md.

Все вычисленные выводы относятся к двум предоставленным CSV. Инженерный риск и причины аномалий не верифицированы независимыми данными.